

Relatório de Laboratório

Assistente de IA e codificação manual em katas de Python

Curso	Engenharia de Software
Disciplina	Laboratório de Experimentação de Software
Turno / Período	Noite / 6º
Professor(a)	Danilo Maia
Laboratório	Lab02
Grupo (trio)	Amanda Bicalho · Guilherme de Almeida · Pedro Duarte
Link do repositório / GitHub Projects	https://github.com/guilhermeas04/Laboratorio-de-experimentacao-de-software · https://github.com/users/guilhermeas04/projects/3
Data de entrega	23 de setembro de 2026

1. Introdução

Este laboratório investigou o efeito do uso de um assistente de inteligência artificial generativa sobre a resolução de tarefas de programação, comparando-o com a codificação manual. Três participantes (P01, P02 e P03) resolveram as mesmas seis katas em Python, cada um realizando três trials com apoio de IA e três trials manuais, em ordem contrabalanceada, com limite de 35 minutos por trial. O experimento segue um desenho crossover within-subject, no qual cada participante atua como seu próprio controle.

No formato GQM (Goal-Question-Metric), o objetivo definido foi analisar o uso de assistente de IA generativa na implementação das katas, com o propósito de comparar seu efeito frente à codificação manual, no que diz respeito ao tempo de resolução, defeitos nos testes de aceitação e qualidade estrutural do código, do ponto de vista do grupo. A partir desse objetivo, foram formuladas três questões de pesquisa. A RQ01 investiga se o assistente reduz o tempo necessário para resolver a tarefa, medido pelo tempo até que todos os testes de aceitação passem (`time_to_green_seconds`), com trials que atingem o limite de 35 minutos sem sucesso sendo registrados como censurados em 2.100 segundos. A RQ02 investiga se o assistente reduz a quantidade de defeitos, tendo como métrica primária a taxa de sucesso nos testes (percentual de testes passando) e, como métrica complementar, a quantidade de testes falhando ao final do trial. A RQ03 investiga se o uso do assistente altera a complexidade ciclomática ou a duplicação de código, considerando complexidade ciclomática média e máxima, percentual de duplicação e índice de manutenibilidade calculados com a biblioteca Radon, além de LOC (SLOC) como métrica de controle, incluída porque código produzido com apoio de IA tende a ser mais extenso.

As hipóteses foram estabelecidas antes da análise e documentadas em LAB2/docs/desenho-experimental.md. Para a RQ01, a hipótese nula é de que a mediana da diferença pareada de tempo (IA – manual) é zero, contra a hipótese alternativa de que essa mediana é negativa. Para a RQ02, a hipótese nula é de que a mediana da diferença pareada da taxa de sucesso é zero, contra a alternativa de que essa mediana é positiva. Para a RQ03, a hipótese nula é de que, para cada métrica estrutural, a mediana da diferença pareada é zero, contra a alternativa de que ao menos uma métrica apresenta diferença mediana distinta de zero; nesse caso foi aplicado teste bicaudal para as cinco métricas, com correção de Holm e $\alpha = 0,05$. Em todas as comparações, a análise utilizou mediana e IQR, com o teste de Wilcoxon signed-rank exato, pareado por participante (mediana dos três trials com IA contra a mediana dos três trials manuais da mesma pessoa). Com apenas três pares por comparação, o menor p-valor unilateral possível é 0,125, uma limitação estrutural da amostra que é considerada em toda a discussão dos resultados.

2. Contexto

A unidade experimental deste laboratório é o trial: uma combinação de um participante, uma kata e um tratamento (com IA ou manual). A tabela oficial de contrabalanceamento está registrada em LAB2/data/design/counterbalancing.csv e contém 18 linhas, correspondentes aos 18 trials válidos do estudo; um arquivo adicional (data/raw/P01-K01-MANUAL.json) não consta nessa tabela e foi mantido fora das análises por não fazer parte do desenho oficial.

Nos registros do experimento, os participantes são identificados como P01 (guilhermeas04), P02 (pedrorodriguesduarte) e P03 (mantido anonimizado como P03). Cada participante resolveu cada uma das seis katas uma única vez, de modo que não existe repetição da mesma pessoa na mesma kata sob os dois tratamentos. O

código final entregue está armazenado em LAB2/code/submissions/, os registros de tempo e de resultados dos testes em LAB2/data/raw/, e as métricas estruturais calculadas sobre o código final em LAB2/data/processed/metrics-<trial_id>.json. O acompanhamento do processo do grupo é realizado por meio do quadro Kanban do GitHub Projects vinculado ao repositório do laboratório, dando continuidade à prática iniciada no Lab01.

3. Metodologia

3.1 Principais Desafios

O principal desafio metodológico foi conciliar um desenho experimental rigoroso com uma amostra muito pequena: apenas três participantes e três pares por comparação, o que limita a 0,125 o menor p-valor unilateral alcançável mesmo no cenário mais favorável ao assistente. Outro desafio relevante foi a inconsistência no registro do assistente utilizado: o protocolo previa uma única ferramenta para todo o grupo, mas os arquivos de trial mostram duas ferramentas distintas em uso — ChatGPT (P01 e P02) e GitHub Copilot, versão 2026-09-16 (P03) —, sendo que, no caso do ChatGPT, o campo de versão não identifica o modelo utilizado. Essa divergência exigiu documentação cuidadosa para não comprometer a interpretação da RQ01.

A presença de tempos extremamente curtos nos trials de P01 — cinco dos seis tempos oficiais abaixo de 5 segundos — também representou um desafio de interpretação, pois esses valores, embora coerentes com os arquivos JSON coletados e mantidos na base, dificultam sustentar que representam de fato o tempo de resolução da tarefa. Adicionalmente, a RQ02 não apresentou nenhuma variação entre tratamentos (todas as diferenças pareadas de taxa de sucesso foram iguais a zero), tornando o teste de Wilcoxon not_applicable para essa questão, já que não há variação para ordenar. Por fim, como o teste de Wilcoxon foi implementado pelo próprio grupo, sem uso da biblioteca SciPy, foi necessário validar manualmente o tratamento de diferenças pareadas iguais a zero — que não entram no posto — e a aplicação da correção de Holm para as cinco métricas estruturais da RQ03.

3.2 Tomadas de Decisão

O grupo optou por um desenho crossover within-subject contrabalanceado, no qual cada participante executa as seis katas alternando entre os tratamentos com IA e manual, reduzindo o efeito de diferenças individuais de habilidade entre os participantes. O time-box de 35 minutos por trial foi mantido fixo durante toda a coleta, e trials que atingissem esse limite sem sucesso seriam registrados como censurados, com duração de 2.100 segundos e time_to_green_seconds nulo; nenhum dos 18 trials oficiais foi de fato interrompido dessa forma. Registros já gravados não são sobrescritos, preservando a integridade do histórico de coleta.

Para a análise estatística, o grupo decidiu utilizar mediana, quartis e IQR como estatísticas descritivas centrais, dada a distribuição assimétrica esperada em métricas de tempo, e o teste de Wilcoxon signed-rank exato como teste de hipótese, pareado por participante. Diferenças pareadas iguais a zero foram excluídas do posto, conforme a formulação clássica do teste; quando as três diferenças de um par são zero, o resultado é reportado como not_applicable em vez de forçar um p-valor artificial. Para a RQ03, decidiu-se aplicar teste bicaudal com correção de Holm sobre as cinco métricas estruturais, controlando o risco de erro tipo I decorrente de múltiplas comparações. A inclusão do LOC (SLOC) como métrica de controle, e não como métrica de interesse direto, foi uma decisão deliberada para verificar se eventuais ganhos de tempo com IA vêm acompanhados de código mais extenso. As métricas estruturais foram calculadas com Radon sobre o código final de cada trial, e a duplicação foi definida como o percentual de linhas úteis em blocos repetidos de pelo menos quatro linhas, após remoção de comentários, linhas vazias e indentação — critério próprio do grupo, distinto de ferramentas como o PMD CPD.

3.3 Etapas

A execução do Lab02 seguiu um pipeline de ferramentas de linha de comando desenvolvidas pelo próprio grupo, acompanhado pelo quadro do GitHub Projects. Primeiro, o desenho de contrabalanceamento é validado com o comando lab02-design --check, que confere a consistência da tabela de 18 trials. Em seguida, a coleta de cada trial é realizada com a CLI lab02-trial, que inicia a cronometragem antes de o enunciado da kata ser liberado ao participante e, ao final, grava o número de testes totais e passando e, apenas nos trials com IA, a contagem de prompts utilizados. As métricas estruturais do código final de cada trial são então calculadas pela ferramenta lab02-metrics, com base no Radon. Por fim, as análises estatísticas das questões de pesquisa são executadas pelos comandos lab02-rq12 (tempo e defeitos, RQ01 e RQ02) e lab02-rq3 (métricas estruturais, RQ03), este último com a opção --check-completeness para confirmar que as 18 métricas estão completas antes da geração dos resultados finais deste relatório.

3.4 Ferramentas

Ferramenta	Versão ou tecnologia	Utilização
Python	3.13.7	Implementação das katas, das CLIs de coleta e das análises estatísticas
Radon	6.0.1	Cálculo de LOC (SLOC), complexidade ciclomática média e máxima, duplicação e índice de manutenibilidade (RQ03)
lab02-trial	CLI própria do grupo	Cronometragem dos trials e registro de testes passando/falhando e prompts
lab02-metrics	CLI própria do grupo	Extração das métricas estruturais do código final de cada trial via Radon
lab02-rq12	Script Python próprio (sem SciPy)	Cálculo de mediana, quartis, IQR e teste de Wilcoxon exato unilateral para RQ01 e RQ02
lab02-rq3	Script Python próprio (sem SciPy)	Wilcoxon bicaudal com correção de Holm e verificação de completude para RQ03
ChatGPT	Versão não identificada no JSON	Assistente de IA utilizado por P01 e P02 nos trials com IA
GitHub Copilot	2026-09-16	Assistente de IA utilizado por P03 nos trials com IA
Git / GitHub	—	Versionamento dos scripts, dados, submissões e relatório
GitHub Projects	v2	Organização das atividades do grupo em quadro Kanban
JSON / CSV	Formatos de dados	Armazenamento dos registros de trial (raw), métricas processadas e tabela de contrabalanceamento

3.5 Tabela de Métricas

RQ	Métrica	Definição Operacional	Unidade
RQ01	Tempo até sucesso	time_to_green_seconds: tempo decorrido até todos os testes de aceitação passarem; trials sem sucesso em 35 min são censurados em 2.100 s	Segundos
RQ02	Taxa de sucesso	$100 \times \text{testes passando} / \text{testes totais}$ ao final do trial	Percentual
RQ02	Testes falhando	Quantidade de testes de aceitação não aprovados ao final do trial (métrica complementar)	Quantidade
RQ03	LOC (SLOC)	Linhas de código-fonte úteis do arquivo final, via Radon (métrica de controle)	Linhas
RQ03	CC média / máxima	Complexidade ciclomática média e máxima por função, via Radon	Pontos de CC
RQ03	Duplicação	Percentual de linhas em blocos repetidos de 4+ linhas, após remover comentários, linhas vazias e indentação	Percentual
RQ03	Índice de manutenibilidade (MI)	Índice de manutenibilidade calculado pelo Radon sobre o código final	Escala Radon

3.6 Inovações Propostas pelo Grupo (30% da nota)

Como contribuição adicional aos requisitos do enunciado, o grupo implementou o próprio teste de Wilcoxon signed-rank exato em Python, sem depender da biblioteca SciPy, incluindo o tratamento correto de diferenças pareadas iguais a zero (excluídas do posto) e a sinalização explícita de comparações not_applicable quando não há variação para ordenar — situação que de fato ocorreu na RQ02. Essa implementação exigiu validação cuidadosa contra os casos-limite do teste com amostras muito pequenas ($n = 2$ ou $n = 3$ pares).

A segunda inovação foi a inclusão do LOC (SLOC) como métrica de controle na RQ03, não solicitada como métrica de interesse direto, mas incorporada para verificar se eventual redução de tempo com o assistente de IA estaria associada a código mais extenso e, portanto, potencialmente menos revisado. Essa decisão permitiu identificar que o código produzido com IA foi de fato mais longo (mediana de 32 linhas contra 25 no manual), sem aumento correspondente de complexidade ciclomática.

A terceira inovação foi a aplicação de correção de Holm para as cinco comparações bicaudais da RQ03, controlando o risco de erro tipo I decorrente de múltiplas comparações — cuidado metodológico que não é trivial em desenhos com n tão pequeno. Por fim, o grupo implementou uma verificação automática de completude

(lab02-rq3 --check-completeness) que confirma que as 18 métricas estruturais estão presentes e com status ok antes da geração dos resultados, reduzindo o risco de conclusões baseadas em dados parciais.

4. Resultados

4.1 Coleta de Dados

Foram analisados os 18 trials oficiais previstos na tabela de contrabalanceamento, todos com status completo. Nos 18 trials, 5 dos 5 testes de aceitação passaram, resultando em taxa de sucesso de 100% e censored = false em todos os casos; nenhum trial oficial foi interrompido pelo limite de 35 minutos. As 18 métricas estruturais correspondentes também estão completas, todas com status = ok segundo a verificação automática de completude. Um arquivo adicional (P01-K01-MANUAL.json) não pertence à tabela oficial de contrabalanceamento e foi mantido fora das análises.

4.2 Visualização Gráfica

4.2.1 RQ01 — Tempo

RQ01: o assistente reduz o tempo para resolver a tarefa?




Figura 1 — Tempo de cada trial oficial, por participante e tratamento (escala logarítmica). Fonte: Elaboração própria.




Figura 2 — Mediana dos três trials de cada participante, por tratamento. Fonte: Elaboração própria.

Tratamento	n	Mediana (s)	IQR	Mínimo	Máximo
------------	---	-------------	-----	--------	--------

Com IA	9	18,073	36,900	0,135	308,704
Manual	9	24,712	375,137	0,143	487,280

Participante	Mediana com IA	Mediana manual	IA – manual
P01	0,183	0,183	0
P02	48,279	322,484	-274,205
P03	18,073	26,657	-8,584

A mediana geral do tempo foi menor com IA (18,073 s) do que no tratamento manual (24,712 s). Como a diferença pareada de P01 é exatamente zero, ela não entra no posto do teste, restando apenas dois pares efetivos. O teste de Wilcoxon unilateral (hipótese de que a IA é mais rápida) resultou em $n = 2$, $W^+ = 0$, p exato = 0,25, não rejeitando H_0 . A maior parte da redução de tempo está concentrada em P02 (-274,2 s na diferença das medianas), com contribuição menor de P03 (-8,6 s). O tempo máximo observado no tratamento manual foi de 487,280 s (P02-K03-MANUAL) e, com IA, de 308,704 s (P02-K01-AI). Em P01, cinco dos seis tempos oficiais ficam abaixo de 5 segundos; esses valores constam nos arquivos JSON originais e foram mantidos na análise.

4.2.2 RQ02 — Defeitos

RQ02: o assistente reduz a quantidade de defeitos?

Nos dois tratamentos, a mediana da taxa de sucesso foi de 100% e a mediana de testes falhando foi de 0, com IQR igual a zero em ambos os casos. As três diferenças pareadas por participante são iguais a zero, de modo que os dois testes de Wilcoxon da RQ02 resultam em `not_applicable`, por ausência de variação para ordenar. Como os testes de aceitação são congelados e idênticos nos dois tratamentos, e ambos os tratamentos os satisfizeram integralmente nesta amostra, não há gráfico de defeitos a apresentar, uma vez que as barras seriam idênticas.

4.2.3 RQ03 — Estrutura do Código

RQ03: o assistente altera a complexidade ciclomática ou a duplicação do código?




Figura 3 — LOC e complexidade ciclomática média nos 18 trials, por tratamento. Fonte: Elaboração própria.




Figura 4 — Índice de manutenibilidade (Radon) nos 18 trials, por tratamento. Fonte: Elaboração própria.

Métrica	Mediana IA	Mediana manual	IQR IA	IQR manual
LOC	32,0	25,0	14,5	25,5
CC média	13,0	14,0	14,5	13,5
CC máxima	13,0	14,0	13,5	13,5
Duplicação (%)	0	0	0	0
Manutenibilidade	50,727	50,874	5,223	12,925

Métrica	n pares	W+	p	Holm	Rejeita H0
LOC	3	3,0	1,0	0,0125	Não
CC média	3	2,0	1,0	0,0167	Não
CC máxima	3	2,0	1,0	0,025	Não
Duplicação	0	—	—	—	Não
Manutenibilidade	3	3,0	1,0	0,05	Não

A complexidade ciclomática praticamente não se alterou entre os tratamentos (mediana de 13 com IA contra 14 no manual), e o índice de manutenibilidade permaneceu próximo em ambos os casos (50,7 e 50,9). A duplicação foi de 0% nos 18 arquivos, de modo que o teste de Wilcoxon dessa métrica não foi executado. O LOC mediano foi maior com IA (32 contra 25 linhas), confirmando a hipótese de verbosidade que motivou a inclusão dessa métrica de controle, sem que esse aumento de linhas tenha sido acompanhado por aumento de complexidade. Todos os p-valores bicaudais calculados foram 1,0, e nenhuma métrica rejeitou H0 mesmo antes da correção de Holm. Entre os extremos mantidos na base estão o menor LOC (P03-K02-AI, 12 linhas), o maior LOC e maior CC (P02-K05-MANUAL, 47 linhas e CC 27), a menor CC média (P01-K03-AI, 5) e os valores extremos de manutenibilidade (mínimo em P01-K04-MANUAL, 42,33; máximo em P03-K02-AI, 63,438). Como os 18 trials passaram em 100% dos testes, nenhuma métrica precisou ser imputada como zero por ausência de solução funcional.

4.3 Discussão

Na RQ01, a mediana geral de tempo com IA (18,073 s) ficou abaixo da manual (24,712 s), na direção da hipótese alternativa, mas o teste não confirma essa direção de forma estatisticamente significativa: $p = 0,25$, com apenas dois pares efetivos, pois P01 empatou em 0,183 s nos dois tratamentos. A redução está concentrada em P02 (−274 s na diferença das medianas), com contribuição bem menor de P03 (−8,6 s). Enquanto os registros de tempo de P01 — da ordem de décimos de segundo — permanecerem na base, a RQ01 descreve fielmente o arquivo coletado, mas não sustenta, com o rigor estatístico necessário, que o assistente reduziu o tempo de resolução.

Na RQ02, não há defeito residual em nenhum dos dois tratamentos, o que impede qualquer contraste estatístico da hipótese de redução de falhas. Esse teto de 100% pode decorrer do tamanho reduzido das katas, do perfil dos participantes, ou de submissões concluídas antes do próprio limite do cronômetro. O protocolo previa censura de trials aos 35 minutos, mecanismo que não se manifestou em nenhum dos 18 trials oficiais.

Na RQ03, a complexidade ciclomática média não mudou de forma relevante entre tratamentos, e o índice de manutenibilidade permaneceu praticamente equivalente. A duplicação, igual a zero nos dois lados, não diferenciou os tratamentos. O LOC mediano foi maior com IA, evidenciando o efeito de verbosidade que a métrica de controle foi incluída para capturar, sem que esse acréscimo de linhas tenha sido acompanhado por aumento de

complexidade ciclomática. Todos os p-valores bicaudais calculados ficaram acima do limiar exigido pela correção de Holm.

Ameaças à validade

- A amostra é de apenas três participantes, e o teste de Wilcoxon nesta configuração não atinge $\alpha = 0,05$ nem no cenário mais extremo possível (menor p unilateral = 0,125).
- Há dois assistentes de IA distintos nos trials com IA (ChatGPT e GitHub Copilot), e a versão do ChatGPT registrada nos arquivos não identifica o modelo utilizado, o que compromete a interpretação do efeito como atribuível a uma única ferramenta.
- As katas K01 a K04 partem de problemas de programação já publicados, com contrato e casos de teste escritos pelo grupo, mas sem gabarito no repositório; ainda assim, o assistente de IA pode ter reconhecido e reproduzido soluções conhecidas para essas famílias de problema, o que representa uma ameaça de memorização específica da RQ01.
- Os tempos muito curtos registrados para P01 (abaixo de alguns segundos em cinco dos seis trials) afetam diretamente a RQ01 e foram mantidos na base sem remoção, por não haver critério objetivo definido a priori para descartá-los.
- O detector de duplicação utilizado é uma implementação própria do grupo, não equivalente ao PMD CPD; um resultado de 0% significa apenas que o critério de blocos repetidos de quatro linhas não encontrou repetição, não que não exista nenhuma similaridade estrutural entre soluções.
- As métricas de LOC, complexidade ciclomática e manutenibilidade não avaliam se outra pessoa compreenderia ou manteria facilmente a solução entregue; são medidas estruturais, não medidas de legibilidade humana.

5. Conclusão

Nos 18 trials oficiais analisados, o uso do assistente de IA não apresentou efeito estatisticamente significativo sobre tempo de resolução, quantidade de defeitos ou estrutura do código, dentro dos limites impostos por uma amostra de apenas três participantes. O tempo mediano de resolução foi menor com IA, mas o teste de Wilcoxon pareado não rejeitou H_0 ($p = 0,25$), e parte dos tempos registrados é curta demais para representar de forma confiável o esforço de resolução da tarefa. Os defeitos não diferiram entre tratamentos porque ambos fecharam integralmente os cinco testes de aceitação em todos os trials oficiais. A complexidade ciclomática e a manutenibilidade permaneceram próximas nos dois tratamentos, a duplicação foi nula nos dois lados, e o código produzido com IA apresentou mais linhas, sem aumento correspondente de complexidade.

O alcance dessas conclusões está limitado a estas seis katas, a estes três participantes e às ferramentas efetivamente registradas nos arquivos de trial: ChatGPT sem identificação de modelo para P01 e P02, e GitHub Copilot na versão de 16 de setembro de 2026 para P03. As principais limitações do estudo decorrem do tamanho reduzido da amostra, da heterogeneidade dos assistentes utilizados e da presença de katas baseadas em problemas conhecidos, que podem ter favorecido o assistente de IA por reconhecimento de padrão em vez de raciocínio original.

As inovações propostas pelo grupo aumentaram a confiabilidade e a interpretabilidade dos resultados: a implementação própria do teste de Wilcoxon tratou corretamente os casos de empate e de ausência de variação; a inclusão do LOC como métrica de controle evidenciou o efeito de verbosidade do código gerado com IA; a correção de Holm reduziu o risco de conclusões falso-positivas nas cinco comparações da RQ03; e a verificação automática de completude garantiu que os resultados relatados se baseiam nos 18 trials integralmente coletados. Com mais tempo e recursos, o grupo ampliaria a amostra de participantes, padronizaria um único assistente de IA com versão identificável, e incluiria katas adicionais inéditas para reduzir a ameaça de memorização identificada na RQ01.

6. Referências

- Repositório do grupo: github.com/guilhermeas04/Laboratorio-de-experimentacao-de-software
- GitHub Projects: github.com/users/guilhermeas04/projects/3
- RADON. Documentação das métricas cc, raw/sloc e mi. Disponível em: radon.readthedocs.io
- WILCOXON, Frank. Individual comparisons by ranking methods. *Biometrics Bulletin*, v. 1, n. 6, p. 80–83, 1945.

- Desenho e ordem dos trials: LAB2/docs/desenho-experimental.md e LAB2/data/design/counterbalancing.csv
- Números deste relatório: saídas de lab02-rq12 e lab02-rq3, em LAB2/reports/